LAPORAN PRAKTIKUM ENSEMBLE METHOD DAN CLASS IMBALANCE

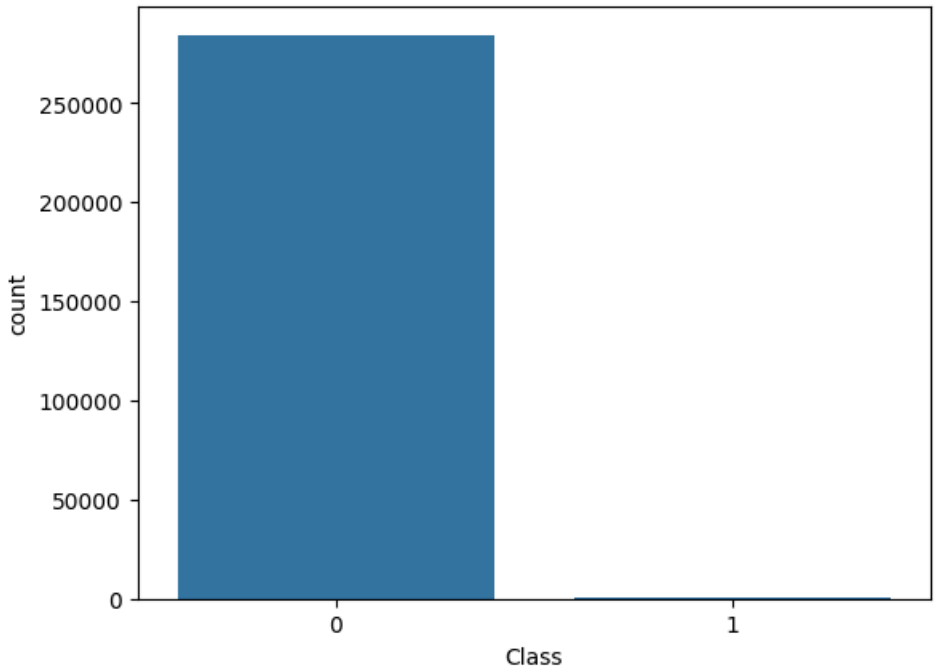
Klasifikasi penipuan kartu kredit dengan Random Forest dan perbandingan enam pendekatan sampling

Nama : Daffa Aufa Afif
NRP : 5054251022

Laporan ini membandingkan Random Forest pada data asli dan lima teknik penanganan ketidakseimbangan kelas. Fokus analisis adalah kemampuan menangkap transaksi fraud tanpa menghasilkan terlalu banyak prediksi meleset. Pada data uji yang sama, metode sampling ADASYN memberi kompromi terbaik secara keseluruhan.

1. Dataset dan EDA

Dataset Credit Card Fraud Detection berisi 284.807 transaksi dan 31 kolom, termasuk target Class (0 = normal, 1 = fraud). Notebook menunjukkan tidak ada nilai hilang. Sebelum pembersihan duplikat, kelas normal mencakup 99,8273% data dan fraud hanya 0,1727%. Dengan distribusi seperti ini, model yang selalu menebak normal bisa tampak sangat akurat tetapi gagal menemukan fraud.



Gambar 1. Distribusi kelas awal menunjukkan dominasi transaksi normal.

Pemeriksaan nilai ekstrim(outlier) juga dilakukan pada fitur V1 sampai V28. Nilai tersebut tidak dihapus karena terbukti dapat membawa sinyal fraud. Baris duplikat dihapus, lalu data dibagi menjadi 80% latih dan 20% uji dengan stratifikasi(stratify=y) agar proporsi kelas tetap terjaga. Data uji tidak diubah oleh proses sampling.

2. Rancangan eksperimen

Enam skenario diuji: tanpa sampling(Akan disebut juga sebagai “None”), RandomOverSampler (ROS), RandomUnderSampler(RUS), SMOTE, ADASYN, dan SMOTEENN. Masing-masing memakai RandomForestClassifier dengan parameter: 200 pohon(*n_estimators=200*), random state bernilai 42, dan seluruh inti komputasi yang tersedia. Resampling diterapkan hanya pada data latih, kemudian semua model dievaluasi pada data uji yang sama, yaitu 56.746 transaksi (56.651 normal dan 95 fraud).

2.1 Metode Sampling

Tanpa sampling (None): Data latih dibiarkan dengan distribusi asli. Kelebihannya, seluruh variasi transaksi normal tetap tersedia dan tidak ada contoh buatan; kekurangannya, fraud yang sangat jarang bisa kurang diperhatikan model.

RandomOverSampler (ROS): Metode ini menggandakan contoh fraud secara acak hingga jumlah kelas lebih seimbang. Cara ini sederhana dan mempertahankan nilai data asli, tetapi pengulangan contoh yang sama dapat meningkatkan risiko overfitting serta memperbesar data latih.

RandomUnderSampler (RUS): Metode ini membuang sebagian transaksi normal secara acak. Pelatihan menjadi lebih cepat dan ringan, tetapi banyak informasi tentang variasi transaksi normal hilang; pada eksperimen ini dampaknya terlihat dari banyaknya false positive.

SMOTE: Metode ini membentuk contoh fraud sintetis melalui interpolasi antara contoh fraud yang berdekatan. Data minoritas menjadi lebih beragam tanpa sekadar digandakan, tetapi contoh sintetis dapat kurang tepat ketika kelas saling tumpang tindih atau terdapat noise.

ADASYN: Seperti SMOTE, metode ini membuat contoh sintetis, tetapi lebih banyak pada fraud yang sulit dipelajari karena berada dekat contoh kelas lain. Pendekatan ini dapat membantu pembelajaran di batas kelas, namun berisiko memperkuat noise atau outlier dan menambah ukuran data latih.

SMOTEENN: Metode ini menjalankan SMOTE lalu Edited Nearest Neighbours (ENN) untuk membuang contoh yang labelnya tidak selaras dengan tetangganya. Area kelas yang tumpang tindih dapat menjadi lebih bersih, tetapi pembersihan juga bisa menghapus contoh penting dan membutuhkan proses tambahan.

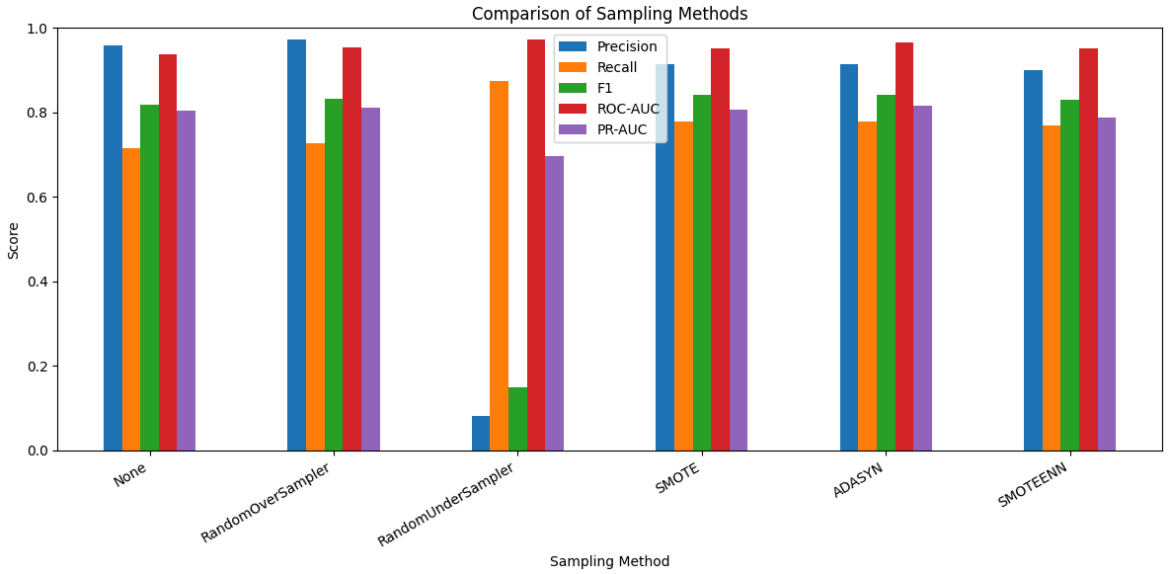
Precision mengukur proporsi prediksi fraud yang benar, recall mengukur bagian fraud yang berhasil ditemukan, F1 merangkum precision dan recall, ROC AUC menilai kemampuan pemeringkatan di berbagai ambang, sedangkan PR AUC lebih peka terhadap kualitas prediksi kelas fraud yang sangat langka. Confusion matrix dipakai untuk melihat jumlah fraud terlewat dan alarm palsu secara langsung.

3. Hasil evaluasi

Tabel 1 memuat metrik kelas fraud dari output notebook. Jumlah data latih berbeda karena setiap teknik mengubah komposisi data dengan cara yang berbeda.

Metode	Data latih	Precision	Recall	F1	ROC AUC	PR AUC
Tanpa sampling	226.980	0,9577	0,7158	0,8193	0,9385	0,8036
ROS	453.204	0,9718	0,7263	0,8313	0,9548	0,8108
RUS	756	0,0817	0,8737	0,1494	0,9732	0,6956
SMOTE	453.204	0,9136	0,7789	0,8409	0,9518	0,8065
ADASYN	453.348	0,9136	0,7789	0,8409	0,9666	0,8169
SMOTEENN	314.790	0,9012	0,7684	0,8295	0,9512	0,7882

Tabel 1. Perbandingan performa Random Forest pada enam skenario.

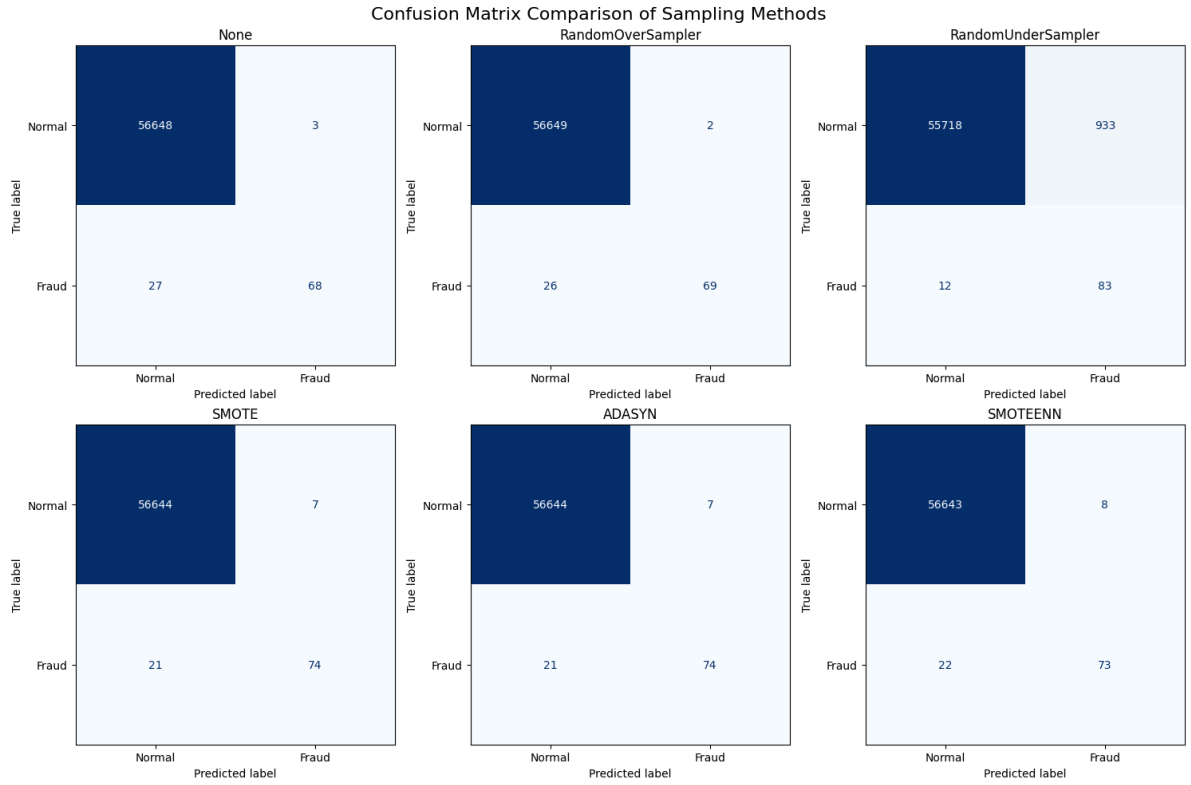


Gambar 2. Perbandingan precision, recall, F1, ROC AUC, dan PR AUC.

4. Pembahasan

4.1 Interpretasi confusion matrix

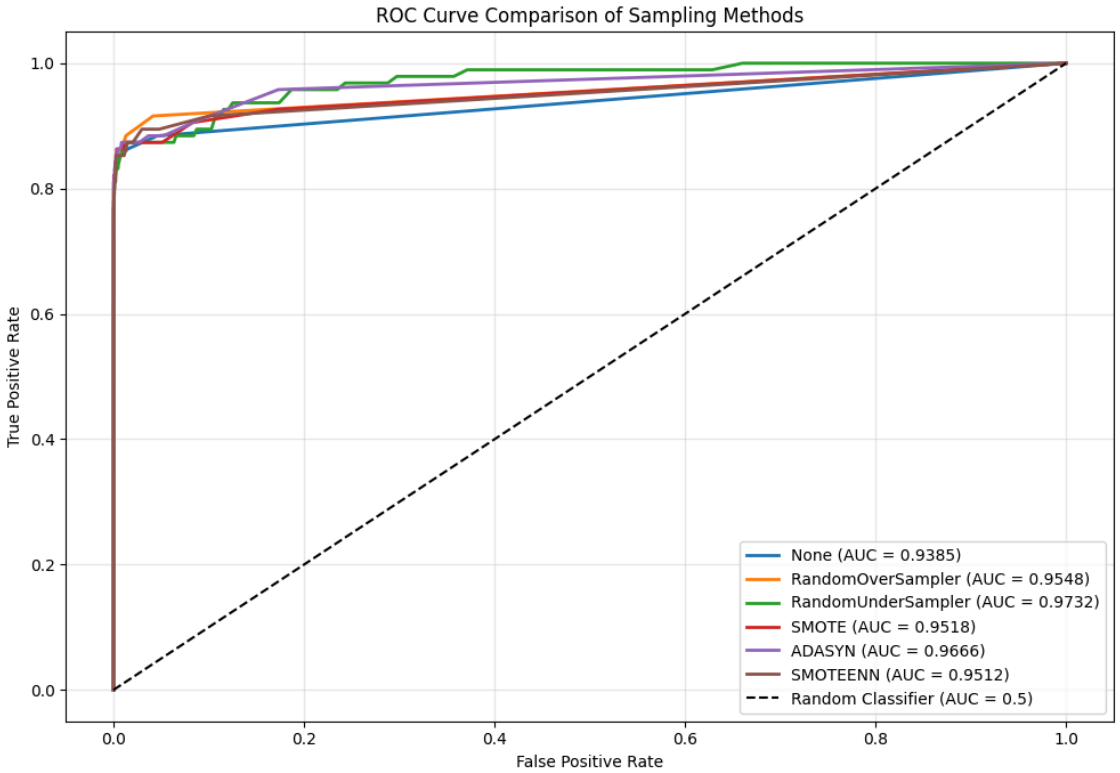
Tanpa sampling, model mengenali 68 dari 95 fraud, melewatkan 27 fraud, dan memberi 3 *false positive*. Ini hasil yang cukup baik: precision 0,9577 dan F1 0,8193, tetapi recall 0,7158 masih menyisakan lebih dari seperempat fraud pada data uji.



Gambar 3. Confusion matrix keenam skenario. Baris menunjukkan kelas sebenarnya dan kolom menunjukkan kelas prediksi.

RandomUnderSampler hanya melatih model dengan 756 transaksi. Skenario ini menemukan fraud terbanyak, yaitu 83 dari 95 (recall 0,8737), dan meraih ROC AUC 0,9732. Namun, 933 transaksi normal diprediksi sebagai fraud. Angka 933 adalah false positive, sedangkan 12 fraud yang diprediksi normal adalah false negative. Akibatnya precision turun menjadi 0,0817: dari setiap sekitar 12 alarm fraud, hanya satu yang benar. F1 dan PR AUC juga menjadi yang terendah. Hilangnya sebagian besar contoh normal saat undersampling kemungkinan membuat model kurang mengenali variasi transaksi sah.

SMOTE dan ADASYN masing-masing menemukan 74 fraud, melewatkan 21 fraud, serta memberi 7 alarm palsu. Keduanya berbagi F1 tertinggi (0,8409). ADASYN unggul pada PR AUC (0,8169, tertinggi) dan ROC AUC (0,9666) dibanding SMOTE (0,8065 dan 0,9518). Karena itu, ADASYN merupakan pilihan terbaik pada eksperimen ini bila tujuan utamanya keseimbangan deteksi fraud dan alarm palsu. Bila biaya melewatkan fraud jauh lebih tinggi daripada biaya meninjau alarm palsu, RandomUnderSampler dapat dipertimbangkan, tetapi ambang keputusan dan kapasitas pemeriksaan transaksi perlu ditentukan lebih dulu.



Gambar 4. Kurva ROC seluruh skenario; AUC tertinggi tidak selalu berarti precision terbaik.

4.2 Random Forest dan ketidakseimbangan kelas

Random Forest cukup tahan terhadap ketidakseimbangan karena menggabungkan banyak pohon yang dilatih pada sampel bootstrap dan subset fitur. Pola fraud yang kuat pada beberapa fitur masih dapat muncul pada sebagian pohon, lalu kontribusinya digabungkan dalam prediksi akhir. Hal ini terlihat dari hasil tanpa sampling yang masih memperoleh precision tinggi dan mendeteksi 68 fraud. Namun mekanisme tersebut tidak menjamin kelas langka mendapat perhatian yang cukup: hampir semua sampel latih adalah normal, sehingga banyak pemisahan pada pohon lebih menguntungkan kelas mayoritas. Model dasar tetap melewatkan 27 fraud.

Sampling tetap perlu dicoba untuk memberi sinyal kelas fraud lebih besar selama pelatihan dan menguji apakah recall meningkat tanpa penurunan precision yang tidak dapat diterima. Eksperimen ini menunjukkan hasilnya bergantung pada metode: oversampling sintetis memberi kenaikan recall dan F1 yang moderat, sedangkan undersampling ekstrem menaikkan recall tetapi mengorbankan precision. Karena itu pemilihan metode harus memakai metrik kelas fraud dan confusion matrix pada data uji asli, bukan accuracy saja.

5. Kesimpulan

Random Forest tanpa sampling sudah menghasilkan evaluasi dasar yang layak, tetapi melewatkan 27 dari 95 fraud. ADASYN merupakan metode sampling terbaik secara seimbang pada percobaan ini: F1 0,8409, PR AUC 0,8169, 74 fraud terdeteksi, dan 7 false positive. RandomUnderSampler memberi recall dan ROC AUC tertinggi, tetapi 933 false positive membuat precision dan F1 paling rendah. Hasil ini menegaskan bahwa kenaikan recall perlu dibaca bersama banyaknya *false alarm* dan kualitas precision pada kelas minoritas.