Tugas Praktikum 2: Praproses Data

Dataset House Prices – Advanced Regression Techniques

Daffa Aufa Afif (5054251022)

1. Pendahuluan

Laporan ini merangkum tahapan praproses data yang dilakukan pada dataset "*House Prices – Advanced Regression Techniques"* (file train.csv), sebuah dataset properti rumah yang umum digunakan pada kompetisi Kaggle untuk regresi harga jual rumah (kolom target *SalePrice*).

Dataset awal terdiri dari 1.460 baris dan 81 kolom(fitur), mencakup atribut numerik (luas tanah, luas bangunan, tahun dibangun, dan lainnya.) maupun atribut kategorikal (kualitas material, tipe garasi, kondisi basement, dsb.). Seluruh tahapan pada laporan ini mengikuti urutan proses pada notebook, yaitu:

1. Pembersihan Data,
2. Deteksi dan Penanganan Outlier,
3. Transformasi Data,
4. Reduksi Dimensi.

2. Pembersihan Data

2.1 Pemeriksaan Missing Value (NaN)

Pemeriksaan awal dengan df.info() dan perhitungan isna().sum() per kolom menunjukkan bahwa dari 81 kolom, terdapat 7.829 sel bernilai NaN yang tersebar pada 19 kolom. Empat kolom teratas dengan proporsi NaN terbesar adalah Alley, PoolQC, Fence, dan MiscFeature, yang mayoritas datanya (bahkan hingga 100%) merupakan nilai kosong.

Kolom	% NaN	Keterangan
PoolQC	100%	Di-drop (> 50%)
MiscFeature	96%	Di-drop (> 50%)
Alley	94%	Di-drop (> 50%)
Fence	81%	Di-drop (> 50%)
MasVnrType	60%	Di-drop (> 50%)
FireplaceQu	47%	Dipertahankan – diisi "Kosong" / modus
LotFrontage	18%	Dipertahankan – diisi median per Neighborhood
Garage* (5 kolom)	6%	Dipertahankan – indikasi rumah tanpa garasi
Bsmt* (5 kolom)	3%	Dipertahankan – indikasi rumah tanpa basement
MasVnrArea	1%	Dipertahankan – diisi median
Electrical	≈0%	Dipertahankan – diisi modus

2.2 Drop Kolom dengan Missing Value > 50%

Sesuai ketentuan tugas, kolom dengan proporsi NaN lebih dari 50% di-drop, yaitu Alley, MasVnrType, PoolQC, Fence, dan MiscFeature. Kolom-kolom sisa yang masih memiliki NaN kemudian dipisah menjadi 3 kolom numerik (LotFrontage, MasVnrArea, GarageYrBlt) dan 11 kolom kategorikal (didominasi kelompok Bsmt dan Garage, ditambah Electrical serta FireplaceQu).

2.3 Temuan NaN pada Garasi dan Basement

Hal yang menarik pada dataset ini adalah kelompok kolom Garage(GarageType, GarageFinish, GarageQual, GarageCond, GarageYrBlt) memiliki jumlah NaN yang persis sama(6%), begitu pula kelompok kolom Bsmt(Basement) (3%). Pola ini mengindikasikan bahwa NaN pada kolom-kolom tersebut bukan data yang hilang secara acak, melainkan representasi bahwa rumah tersebut memang tidak memiliki garasi atau basement.

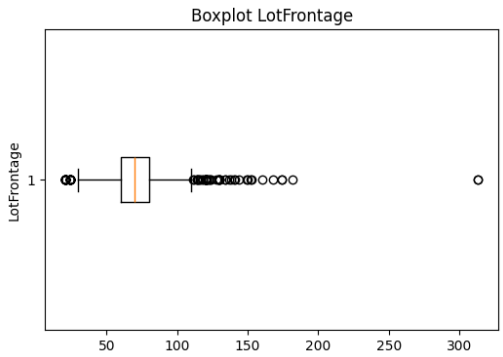
Dugaan ini dibuktikan pada notebook dengan cross-check terhadap kolom terkait yang tidak memiliki NaN, seperti GarageCars, GarageArea, dan TotalBsmtSF. Dibangun variabel boolean has_garage dan has_basement yang bernilai benar jika salah satu indikator numerik/kategorikal terkait terisi. Rumah yang *tidak* memiliki indikasi tersebut lalu diperlakukan berbeda dari rumah yang memilikinya namun datanya kebetulan hilang:

- Rumah tanpa garasi/basement: kolom kategorikal diisi label “Kosong”, kolom numerik seperti GarageCars/GarageArea diisi 0, dan GarageYrBlt diisi tahun pembangunan rumah (YearBuilt) sebagai representasi netral.
- Rumah yang diketahui memiliki garasi/basement namun datanya tetap NaN (murni data hilang): kolom kategorikal diisi modus, dan GarageYrBlt diisi median tahun garasi.

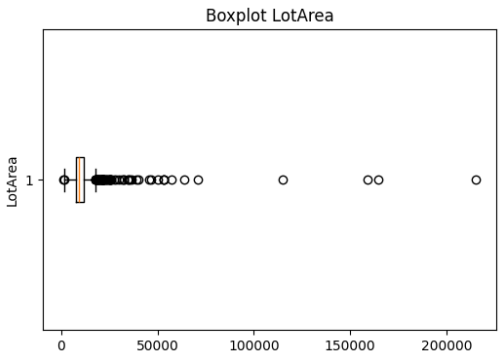
Setelah langkah ini, kolom kategorikal sisanya ditangani dengan imputasi sederhana: Electrical diisi modus, MasVnrArea diisi median, sedangkan LotFrontage diisi median per kelompok Neighborhood (bukan median) agar nilai imputasi lebih merepresentasikan karakteristik lingkungan rumah tersebut. Hasil akhir tahap ini memverifikasi total NaN = 0 pada seluruh dataset.

3. Deteksi dan Penanganan Outlier

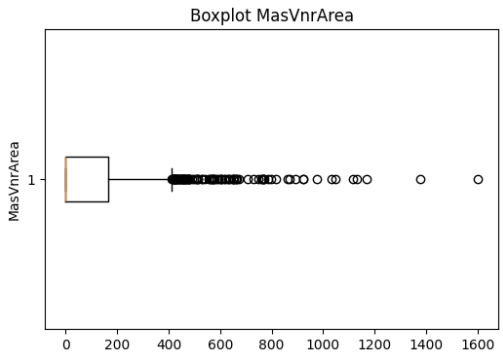
Deteksi outlier dilakukan secara visual menggunakan *boxplot* pada seluruh 36 atribut numerik. Pendekatan ini dipilih karena boxplot secara cepat menampilkan sebaran data beserta titik-titik yang berada di luar rentang wajar (whisker). Berikut contoh boxplot pada lima atribut yang disebutkan pada notebook memiliki observasi ekstrem yang menonjol, yaitu LotFrontage, LotArea, MasVnrArea, TotalBsmtSF, dan OpenPorchSF:



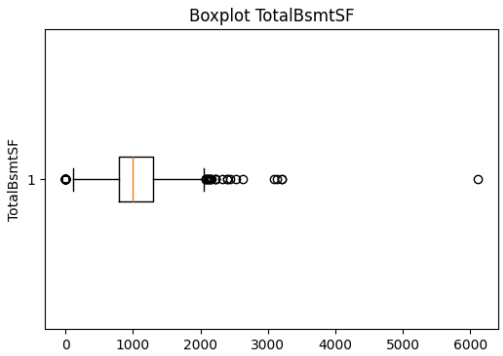
LotFrontage



LotArea

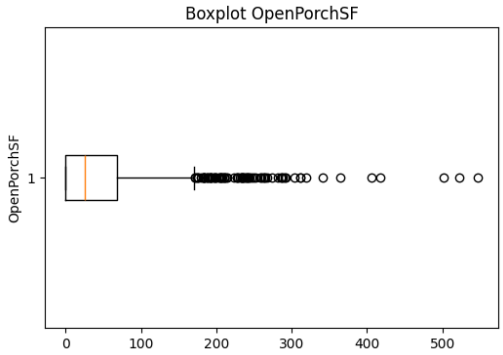


MasVnrArea

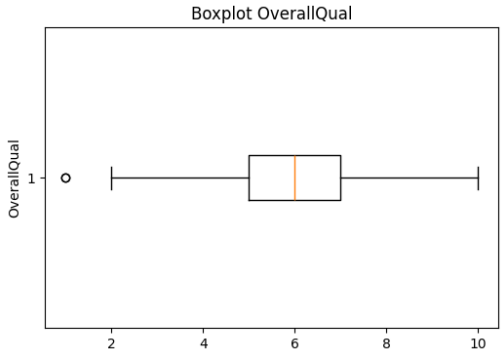


TotalBsmtSF

Boxplot OpenPorchSF (di bawah) menunjukkan pola serupa: sebagian besar rumah bernilai 0 (tidak memiliki porch terbuka), sehingga IQR menjadi sangat kecil dan banyak nilai positif tampak sebagai “outlier” secara statistik walaupun sebenarnya wajar.



OpenPorchSF



OverallQual (pembanding – rentang nilai wajar)

Penanganan Outlier: IQR Capping

Batas bawah/atas dihitung dengan metode IQR standar: Lower = Q1 - 1.5×IQR, Upper = Q3 + 1.5×IQR. Berikut nilai batas untuk kelima fitur yang disorot:

Fitur	Q1	Q3	IQR	Batas Bawah	Batas Atas
LotFrontage	60.00	80.00	20.00	30.00	110.00
LotArea	7.553,50	11.601,50	4.048,00	1.481,50	17.673,50
MasVnrArea	0.00	164.25	164.25	-246.38*	410.63
TotalBsmtSF	795.75	1.298,25	502.50	42.00	2.052,00
OpenPorchSF	0.00	68.00	68.00	-102.00*	170.00

** Batas bawah negatif otomatis tidak berpengaruh karena nilai asli fitur ini tidak pernah negatif.*

Nilai ekstrem tidak dihapus (baris data tetap dipertahankan seluruhnya, 1.460 observasi), melainkan di-“capping” (clip) ke batas bawah/atas. Keputusan ini diambil karena pada dataset perumahan, nilai besar sering kali merepresentasikan properti dengan ukuran/fasilitas yang memang lebih besar (bukan kesalahan

input), dan beberapa atribut memiliki distribusi yang sangat didominasi nilai nol sehingga IQR dapat memberi indikasi outlier yang menyesatkan jika baris datanya dibuang.

4. Transformasi Data

Sebelum pemodelan, fitur dipisah menjadi 36 kolom numerik dan 38 kolom kategorikal (di luar Id dan target SalePrice). Dua teknik transformasi diterapkan:

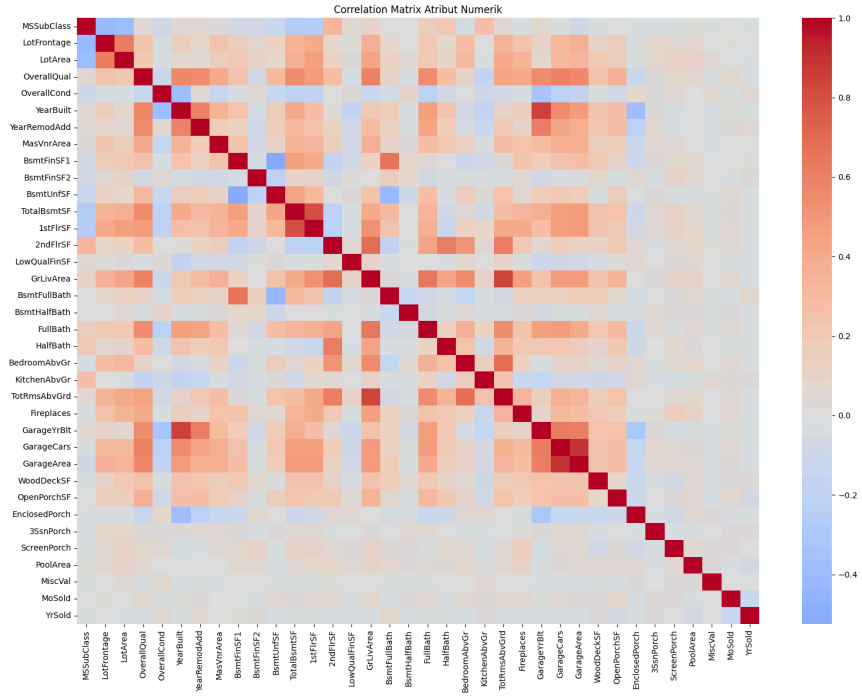
- Standardisasi (StandardScaler): diterapkan pada seluruh kolom numerik agar setiap fitur memiliki mean 0 dan standar deviasi 1, sehingga skala antar-fitur (misalnya LotArea vs OverallQual) tidak saling mendominasi saat pemodelan.
- One-Hot Encoding: diterapkan pada seluruh kolom kategorikal (parameter handle_unknown='ignore' agar tidak error jika ditemukan kategori baru saat inference) untuk mengubah tiap kategori menjadi kolom biner terpisah.

Setelah kedua hasil transformasi digabung (np.hstack), diperoleh matriks fitur berukuran (1.460, 281) — peningkatan signifikan dari 74 kolom asli akibat ekspansi one-hot encoding pada atribut kategorikal.

5. Reduksi Dimensi

5.1 Analisis Korelasi Antar Fitur Numerik

Correlation matrix dihitung pada atribut numerik kontinu dan divisualisasikan dengan heatmap berikut untuk mengidentifikasi fitur yang saling redundan (berkorelasi tinggi):



Pasangan fitur dengan korelasi ≥ 0,80 dianggap redundan, sehingga salah satu fitur pada tiap pasangan (yang secara konsep lebih “turunan”) di-drop:

Pasangan Fitur	Korelasi	Fitur yang Di-drop
GarageCars ↔ GarageArea	0.89	GarageArea
YearBuilt ↔ GarageYrBlt	0.85	GarageYrBlt
GrLivArea ↔ TotRmsAbvGrd	0.84	TotRmsAbvGrd
TotalBsmtSF ↔ 1stFlrSF	0.81	1stFlrSF

Alasannya, mempertahankan kedua fitur pada pasangan berkorelasi sangat tinggi hampir tidak menambah informasi baru bagi model, namun meningkatkan dimensi dan risiko multikolinearitas. Setelah drop keempat kolom tersebut dan mengulang proses standardisasi + one-hot encoding, dimensi fitur berkurang menjadi (1.460, 277).

5.2 Principal Component Analysis (PCA)

Reduksi dimensi lanjutan dilakukan dengan PCA(n_components=0.95), yaitu mempertahankan jumlah komponen minimum yang mampu menjelaskan 95% variansi data. Hasilnya, 277 dimensi berhasil direduksi menjadi 74 komponen utama dengan total explained variance sebesar 95,10%. Dataset akhir (PC1–PC74 beserta kolom Id dan SalePrice) berukuran (1.460, 76).

6. Ringkasan Output

Notebook menghasilkan dua berkas dataset hasil praproses:

- house_prices_cleaned.csv — dataset bersih (bebas NaN, outlier di-capping) sebelum one-hot encoding dan PCA, 76 kolom.
- house_prices_final_pca.csv — dataset akhir hasil standardisasi, one-hot encoding, dan PCA (74 komponen utama + Id + SalePrice), berukuran (1.460, 76).

Kesimpulan

Secara keseluruhan, tahapan praproses pada notebook ini berhasil: menghilangkan seluruh missing value dengan strategi yang mempertimbangkan makna domain (NaN pada Garasi/Basement sebagai “tidak ada”, bukan hilang), menangani nilai ekstrem tanpa kehilangan observasi melalui IQR capping, menstandardisasi dan meng-encode fitur agar siap untuk pemodelan, serta mereduksi dimensi dari 281 menjadi 74 fitur melalui eliminasi fitur berkorelasi tinggi dan PCA, sambil tetap mempertahankan 95% informasi (variansi) dari data asli.