LAPORAN PRAKTIKUM SEQUENTIAL PATTERN MINING

Penemuan Pola Sekuensial Pembelian Pelanggan dalam Dataset Online Retail Menggunakan Algoritma PrefixSpan.

Nama: Daffa Aufa Afif
NRP : 5025251022

1 Dataset dan Exploratory Data Analysis (EDA)

Dataset yang digunakan dalam praktikum ini adalah *Online Retail* yang diperoleh dari UCI Machine Learning Repository. Dataset berformat Excel ini memiliki dimensi awal sebesar 541.909 baris dan 8 kolom atribut, yaitu `InvoiceNo`, `StockCode`, `Description`, `Quantity`, `InvoiceDate`, `UnitPrice`, `CustomerID`, dan `Country`.

Tahap Exploratory Data Analysis (EDA) dilakukan untuk memeriksa struktur data, memvalidasi kualitas data, serta mengidentifikasi anomali transaksi dan perilaku pelanggan sebelum pemrosesan lebih lanjut. Langkah-langkah inspeksi yang dilakukan meliputi:

1. Pemeriksaan Nilai Hilang (*Missing Values*): Terdeteksi sebanyak 136.534 nilai kosong yang terdistribusi pada atribut `CustomerID` (135.080 nilai kosong) dan `Description` (1.454 nilai kosong). Penanganan nilai kosong pada `Description` dilakukan agar tidak ada transaksi dengan nama produk yang tidak terdefinisi, sedangkan pemeriksaan `CustomerID` memastikan identifikasi pembeli yang valid untuk analisis sekuensial.
2. Deteksi Data Duplikat: Ditemukan sebanyak 5.268 baris data duplikat identik. Pembersihan baris duplikat ini bermanfaat untuk mencegah pembobotan ganda pada item dalam keranjang belanja yang sama.
3. Analisis Anomali Transaksi: Dilakukan penelusuran terhadap nilai `Quantity` negatif atau bernilai nol yang menandakan transaksi pembatalan atau retur barang (ditandai dengan huruf ‘C’ pada awal `InvoiceNo`). Selain itu, dilakukan pemeriksaan terhadap atribut `UnitPrice` bernilai nol atau negatif yang mengindikasikan penyesuaian biaya akuntansi internal.
4. Pemeriksaan Konsistensi Timestamp: Ditemukan anomali berupa 43 nomor `InvoiceNo` yang mencatat waktu transaksi berbeda dengan selisih waktu sangat singkat (≈ 1 menit). Hal ini disebabkan oleh *latency* atau jeda pencatatan server POS saat memproses barang belanjaan yang banyak.
5. Analisis Distribusi Pelanggan: Dari total 4.339 pelanggan valid yang teridentifikasi, sebanyak 1.494 pelanggan ($34,43\%$) hanya melakukan 1 kali transaksi (*single transaction*), sedangkan 2.845 pelanggan ($65,57\%$) merupakan pelanggan berulang (*repeat customer*) yang melakukan lebih dari 1 kali transaksi. Rata-rata transaksi per pelanggan adalah sebesar 4,27 invoice dengan jumlah maksimum mencapai 210 invoice per pelanggan.

Seluruh rangkaian EDA ini memberikan pemahaman menyeluruh terhadap kondisi data riil serta memastikan integritas riwayat transaksi pelanggan yang akan disusun menjadi urutan kronologis.

2 Preprocessing dan Formasi Transaksi (Sequence Formation)

Tahap pra-pemrosesan data bertujuan untuk mentransformasi dataset mentah menjadi format struktur data urutan transaksi (*sequence of itemsets*) per pelanggan yang siap diproses oleh algoritma *Sequential Pattern Mining*. Langkah-langkah terstruktur yang dilakukan pada tahap ini adalah sebagai berikut:

1. Pembersihan Data Anomali: Menghapus seluruh baris data transaksi retur (`Quantity <= 0`), harga barang tidak valid (`UnitPrice <= 0`), serta data transaksi tanpa `CustomerID` dan `Description`.
2. Harmonisasi Timestamp Transaction: Mengonsolidasikan catatan waktu `InvoiceDate` pada `InvoiceNo` yang sama dengan mengambil nilai waktu paling awal (`min`), sehingga tidak ada pembagian keranjang belanja yang terpecah akibat jeda waktu sistem.

3. Konsolidasi Itemset per Invoice: Mengelompokkan nama produk (`Description`) yang unik ke dalam satu keranjang belanja (*itemset*) berdasarkan kombinasi `CustomerID` dan `InvoiceNo`.
4. Pembentukan Urutan Kronologis (Sequence Formation): Mengurutkan seluruh *itemset* milik setiap pelanggan berdasarkan waktu transaksi (`InvoiceDate`) secara kronologis. Hasilnya adalah struktur data berwujud *list of itemsets* untuk setiap `CustomerID`.

Hasil akhir dari tahap pra-pemrosesan ini menghasilkan 397.924 baris data bersih ($73,43\%$ dari data awal), yang mencakup 18.536 invoice unik dari 4.339 pelanggan valid.

3 Eksperimen dan Hasil Penambangan Pola Sekuensial

Ekstraksi pola sekuensial dilakukan dengan menerapkan algoritma PrefixSpan (*Prefix-Projected Sequential Pattern Mining*). Penggunaan algoritma PrefixSpan dipilih karena efisiensi komputasinya yang tinggi dalam memproses data sekuensial melalui teknik pemroyeksian basis data (*pattern-projected database*) tanpa perlu membangkitkan kandidat sekuens secara eksplisit.

Eksperimen dijalankan dengan menentukan ambang batas minimum *support* sebesar 1% (`MIN_SUPPORT = 0.01`), yang berarti suatu pola harus muncul minimal pada 44 pelanggan dari total 4.339 pelanggan (`min_support_count = 44`), serta membatasi panjang maksimum pola hingga 3 elemen (`MAX_PATTERN_LENGTH = 3`).

Dari eksperimen ini, berhasil diekstrak sebanyak 34.732 pola sekuensial frekuen. Pola tersebut terdiri dari 1.763 pola beranggotakan 1 produk (*single itemset*) dan 32.969 pola sekuensial multi-item (panjang pola $ge2$). Tiga pola sekuensial multi-item terbaik (Top 3) dengan nilai *Support* dan *Confidence* tertinggi disajikan pada Tabel Tabel 1.

Pola Sekuensial (Transaksi 1 -> Transaksi 2)	Panjang	Jumlah Pelanggan	Support	Confidence
WHITE HANGING HEART T-LIGHT HOLDER -> WHITE HANGING HEART T-LIGHT HOLDER	2	405	0,093339	0,473131
REGENCY CAKESTAND 3 TIER -> REGENCY CAKESTAND 3 TIER	2	330	0,076054	0,374574
JUMBO BAG RED RETROSPOT -> JUMBO BAG RED RETROSPOT	2	312	0,071906	0,491339

Tabel 1: Top 3 Pola Sekuensial Multi-Item Utama pada Dataset Online Retail.

4 Pembahasan

Hasil ekstraksi pola sekuensial pada Tabel Tabel 1 menunjukkan fenomena menarik di mana tiga pola sekuensial teratas didominasi oleh pola pembelian berulang (*repeat purchase*) pada produk yang sama di sesi transaksi berikutnya, yaitu `WHITE HANGING HEART T-LIGHT HOLDER`, `REGENCY CAKESTAND 3 TIER`, dan `JUMBO BAG RED RETROSPOT`.

Analisis terhadap metrik evaluasi memberikan wawasan sebagai berikut:

1. Nilai Support: Pola sekuensial teratas `WHITE HANGING HEART T-LIGHT HOLDER -> WHITE HANGING HEART T-LIGHT HOLDER` memiliki nilai *Support* sebesar $0,093339$, yang menunjukkan bahwa sebanyak 405 pelanggan ($9,33\%$ dari total pelanggan) melakukan pembelian berulang untuk produk penahan lilin tersebut pada sesi belanja yang berbeda.
2. Nilai Confidence: Aturan sekuensial dengan tingkat kepastian tertinggi ditunjukkan oleh produk `JUMBO BAG RED RETROSPOT` dengan nilai *Confidence* sebesar $49,13\%$, disusul oleh `WHITE HANGING HEART T-LIGHT HOLDER` sebesar $47,31\%$. Hal ini mengindikasikan bahwa ketika seorang pelanggan membeli produk *Jumbo Bag* pada transaksi pertama, terdapat peluang sebesar $49,13\%$ bahwa pelanggan tersebut akan kembali membeli produk yang sama pada transaksi berikutnya di lain waktu.

Dari perspektif bisnis dan manajemen ritel, temuan pola sekuensial ini memberikan arahan strategis berikut:

- Strategi Pembelian Ulang (*Repeat Purchase Program*): Mengimplementasikan fitur pengingat re-order otomatis (*automatic replenishment reminder*) atau tawaran diskon khusus berlangganan pada produk-produk kategori *fast-moving/favorite* ini untuk memicu transaksi berulang dalam durasi waktu tertentu.
- Pemasaran Terpersonalisasi (*Retargeting Campaign*): Mengirimkan rekomendasi produk melalui *email marketing* atau promosi terarah setelah pelanggan menyelesaikan transaksi pertama untuk produk-produk yang memiliki tren pembelian ulang tinggi.
- Manajemen Persediaan (*Inventory Control*): Memastikan tingkat stok produk-produk *best-seller* ini selalu terjaga secara konsisten di gudang, karena kehabisan stok pada produk ini dapat menghilangkan potensi pendapatan dari *repeat buyer*.

5 Kesimpulan

Rangkaian praktikum *Sequential Pattern Mining* menggunakan algoritma PrefixSpan pada dataset *Online Retail* telah berhasil mengekstrak sebanyak 34.732 pola sekuensial dari 4.339 pelanggan. Tahap pra-pemrosesan yang ketat terbukti berhasil membentuk struktur data urutan transaksi kronologis yang akurat.

Hasil eksperimen menunjukkan bahwa pola sekuensial utama didominasi oleh perilaku pembelian ulang (*repeat buying*) pada produk dekorasi dan peralatan rumah tangga favorit seperti `WHITE HANGING HEART T-LIGHT HOLDER` dan `JUMBO BAG RED RETROSPOT` dengan nilai *Confidence* mencapai $49,13\%$. Temuan ini memberikan manfaat konkret bagi pihak manajemen ritel dalam merancang strategi retensi pelanggan, promosi berulang, serta pengolahan persediaan barang secara presisi.